La Distancia de Hamming

Adrian Tame Jacobo
Estudiante de Maestría en el ITAM

Introducción

La distancia de Hamming es una herramienta utilizada bastante en el ámbito de la teoría de la información. Es una distancia que definen una manera sencilla para comparar dos secuencias de bits binarias. En la practica, es usada para detección y corrección de errores cuando hay información transmitida entre computadoras. Recientemente, se ha usado también esta distancia en el aprendizaje de similitudes, una area de aprendizaje de máquina supervisada [1]. Su nombre viene del científico Richard Hamming quien la definió originalmente en 1950 en [2]. Mientras que esta distancia fue propuesta para usos prácticos cuando se creó, tiene propiedades interesantes cuando se estudia en el contexto de espacios métricos.

Conceptos de análisis funcional

Para poder entender el contexto de la pregunta en la introducción, se requieren algunas definiciones importantes. Estos son los conceptos de de un espacio métrico y de una medida. Las siguientes definiciones son tomadas también de [3].

Definición 1 (Espacio Métrico, métrica)**.** *Un **espacio métrico** es un par (X, d), donde X es un conjunto y d es una **métrica** en X (una función de distancia en X), esto es, $d : X \times X \to \mathbb{R}$ tal que para todos $x, y \in X$ se cumplen las siguientes propiedades:*

1. *d es real valuada, finita y no-negativa.*
2. *$d(x, y) = 0$ si y solo si $x = y$.*
3. *La propiedad de simetría, esto es, $d(x, y) = d(y, x)$.*
4. *La desigualdad del triangulo, esta es, $d(x, y) \leq d(x, z) + d(z, y)$.*

Con esta definición, podemos seguir y definir el conjunto de bits binarias y la distancia de Hamming para poder tener un espacio métrico.

Conjuntos de bits y la distancia de Hamming

Definición 2. *Sea $\mathbb{F}_2^n$ el conjunto de todas las secuencias de $n \in \mathbb{N}$ bits binarias, generalmente denotadas 0 y 1. Sean u y $v \in \mathbb{F}_2^n$. Entonces, definimos la distancia de Hamming $d(u, v)$ como el número de lugares en donde u y v difieren.*

Para darle claridad al concepto, se presenta un pequeño ejemplo.

Ejemplo. *Sean $u = \{00100\}$ y $v = \{01001\} \in \mathbb{F}_2^5$. Usando la definición pasada, se sigue que $d(u, v) = 3$, ya que las secuencias de bits difieren en la segunda, tercera y quinta posición.*

El intentar demostrar que esta distancia es una métrica puede ser algo complicado ya que no esta definida como un objeto matemático en sí. Pero, después de analizarlo, se puede llegar a la conclusión de que existe una representación un poco mas formal de esta distancia,

$$d(u, v) = \sum_{i=1}^{n} (u_i + v_i \mod 2). \tag{1}$$

El énfasis de este articulo cae bajo esta definición, ya que es equivalente a decir que $d(u, v) = \sum_{i=1}^{n} |u_i - v_i|$. Esto es en términos comunicacionales también equivalente a sumar el resultado de la operación XOR comparando u_i y v_i para cualquier i.

La desigualdad del triangulo para la distancia de Hamming

Mientras que las primeras tres propiedades de una métrica son relativamente fáciles de verificar, la desigualdad del triangulo no es trivial. Es aquí donde la equivalencia 1 es de utilidad. La demostración central se sigue a partir del siguiente lema.

Lema. *Sean $x_1, x_2, C \in \mathbb{N}$, entonces,*

$$(x_1 + x_2) \mod C = (x_1 \mod C) + (x_2 \mod C) \mod C.$$

Demostración. Sean $x_1 \mod C = r_1$ y $x_2 \mod C = r_2$. Entonces, $C \mid (x_1 - r_1)$ y $C \mid (x_2 - r_2)$. Se sigue que $C \mid (x_1 + x_2) - (r_1 - r_2)$. Por lo tanto,

$$\begin{aligned}
&C \mid (x_1 + x_2) - (r_1 - r_2) \\
&\iff x_1 + x_2 \equiv r_1 + r_2 \mod C \\
&\iff (x_1 + x_2) \mod C = (r_1 + r_2) \mod C \\
&\iff (x_1 + x_2) \mod C = ((x_1 \mod C) + (x_2 \mod C)) \mod C.
\end{aligned}$$

□

Podemos ahora proceder al teorema central de este artículo.

Teorema 1. *Sea d la distancia de Hamming. Entonces, $(\mathbb{F}_2^n, d)$ es un espacio métrico.*

Demostración. Las primeras tres propiedades son relativamente triviales y se pueden demostrar usando solamente la definición de d y de el valor absoluto. Para la desigualdad del triangulo con $u, v, w \in \mathbb{F}_2^n$, queremos demostrar que

$$\sum_{i=1}^{n} (u_i + v_i \mod 2) \leq \sum_{i=1}^{n} (u_i + w_i \mod 2) + \sum_{i=1}^{n} (w_i + v_i \mod 2).$$

Veamos que

$$\begin{aligned}
\sum_{i=1}^{n}(u_i + v_i \mod 2) &= \sum_{i=1}^{n}(u_i + (+w_i - w_i) + v_i \mod 2) \\
&\leq \sum_{i=1}^{n}((u_i + w_i) + (w_i + v_i) \mod 2), \quad \text{por Cauchy-Schwartz} \\
&= \sum_{i=1}^{n}(u_i + w_i \mod 2) + (w_i + v_i \mod 2) \mod 2, \quad \text{por el lema,} \\
&= \sum_{i=1}^{n}(u_i + w_i \mod 2) + (w_i + v_i \mod 2).
\end{aligned}$$

□

Implementación computacional

Como notamos antes, esta distancia es equivalente a hacer el operador XOR entre dos diferentes listas de bits. Lo que sigue es una pequeña implementación de la distancia de Hamming en C.

```c
#include <stdint.h>
#include <stdio.h>

int hammingDistance (uint64_t x, uint64_t y) {
 uint64_t res = x ^ y;
 return __builtin_popcountll (res);
}

int main() {
 printf("%d ",hammingDistance(1024,1023));
 return 0;
}
```

El resultado de correr este programa es 11, ya que hay 11 dígitos de diferencia entre 1024 (en binario, esto es 10000000000) y 1023 (en binario, esto es 1111111111). Esta es la implementación más rápida que hemos encontrado, ya que la función *__builtin_popcountll* es una función extremadamente rápida.

Referencias

[1] Mohammad Norouzi, David J Fleet, and Russ R Salakhutdinov. Hamming distance metric learning. In Advances in neural information processing systems, pages 1061–1069, 2012.

[2] Richard W Hamming. Error detecting and error correcting codes. The Bell system technical journal, 29(2):147–160, 1950.

[3] Erwin Kreyszig. Introductory functional analysis with applications, volume 1. wiley New York, 1978.