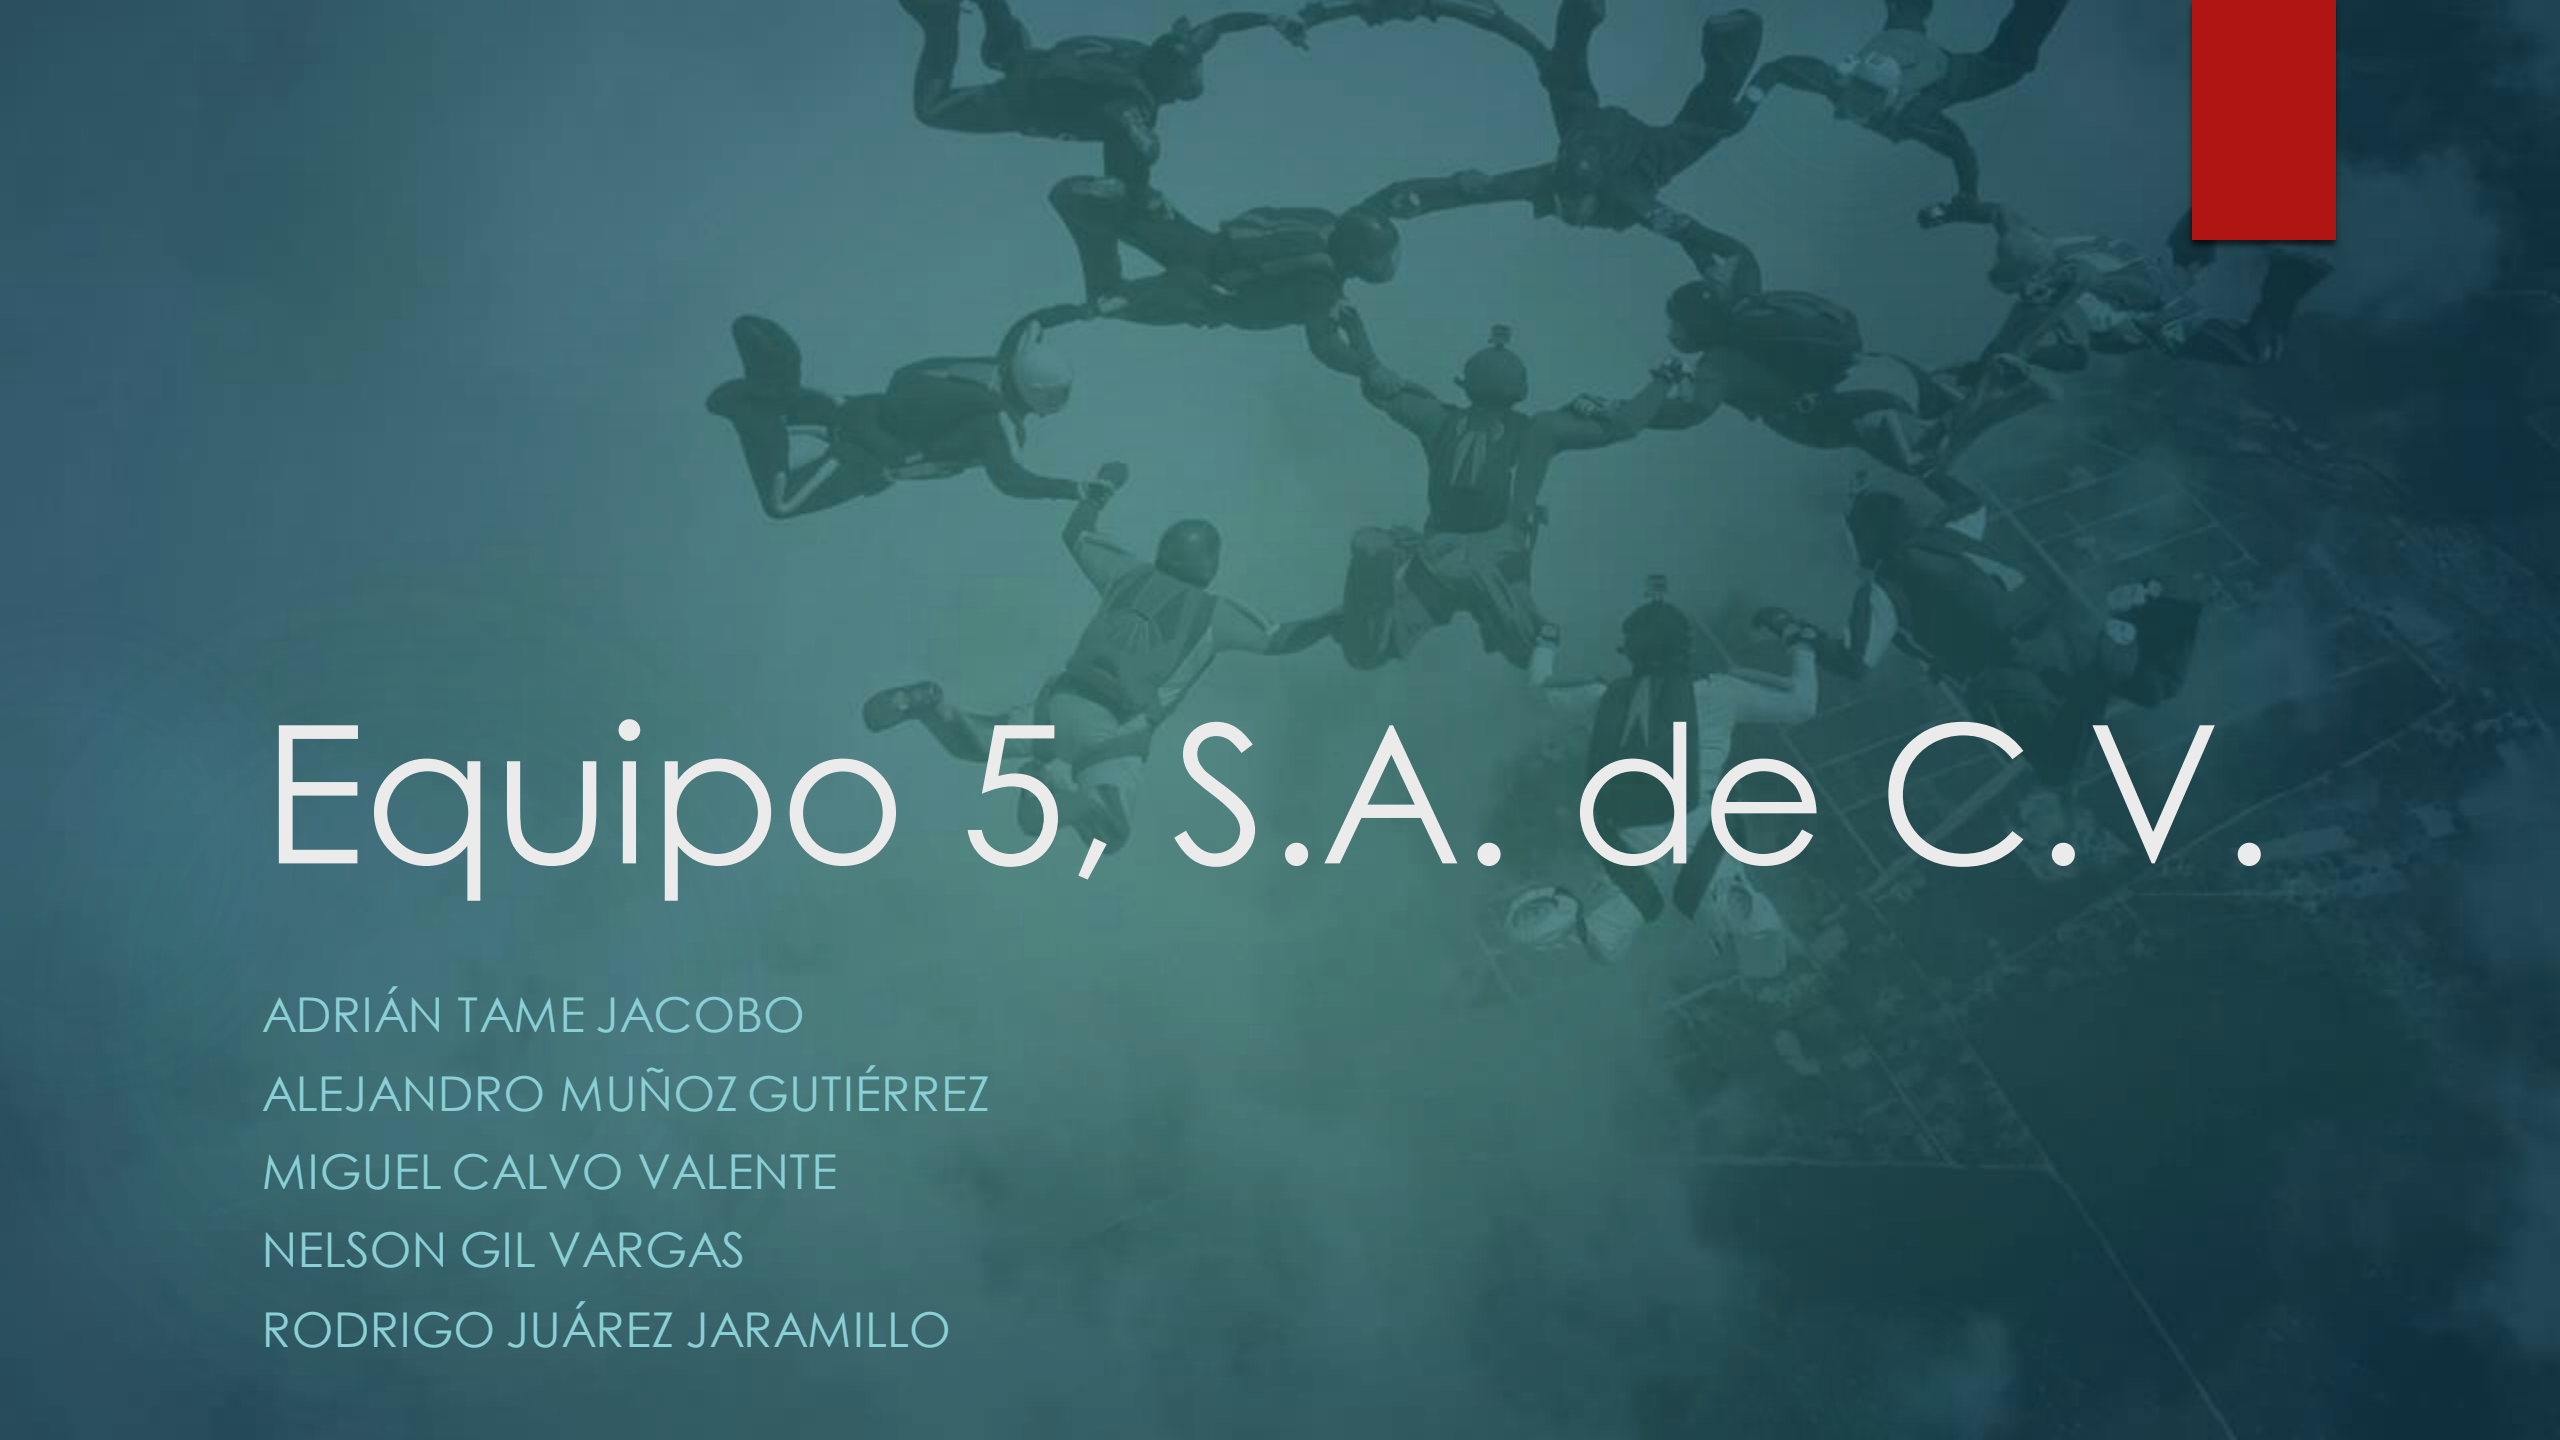


Equipo 5, S.A. de C.V.

ADRIÁN TAME JACOBO
ALEJANDRO MUÑOZ GUTIÉRREZ
MIGUEL CALVO VALENTE
NELSON GIL VARGAS
RODRIGO JUÁREZ JARAMILLO



Problema 1

SOMOS UNA EMPRESA QUE OFRECE SERVICIO DE CONSULTORÍA A LA INDUSTRIA DEL CINE Y LA TELEVISIÓN.

EL CLIENTE ES UN IMPORTANTE PRODUCTOR QUE QUIERE FILMAR UNA PELÍCULA DE LA CUAL OBTENGA GANANCIAS Y QUE GUSTE AL PÚBLICO.



Problema 2

UN SITIO WEB BUSCA DESARROLLAR UN ALGORITMO QUE RECOMIENDE PELÍCULAS A NUEVOS USUARIOS.



Objetivos

- Idealmente, queremos dos cosas:
- 1. Para resolver el primer problema, buscamos saber cuáles son las películas más exitosas y hacer un análisis de las cualidades que tiene una buena película.
- Queremos hacer análisis con base en los directores, presupuesto, género, duración y lenguaje, como algunos ejemplos de variables de interés, para predecir ganancias finales.
- 2. Idealmente, quereos caracterizar o agrupar los usuarios, para que cuando llegue un nuevo usuario, lo podamos asignar a uno de estos grupos, y recomendarle películas. Para esto, seguramente empezaremos con clustering, pero tal vez acabemos con otro modelo. Además, nos gustaría entender las tendencias de ciertos grupos que ven películas.

Alcances y limitaciones

- Una primer limitante es que existen dos bases de datos de dos años diferentes (2020 vs. 2017). Estamos seguros que habrá discrepancias en los ratings de las películas.
- En las primeras exploraciones de nuestros *Datasets,* encontramos que hay valores faltantes principalmente en las variables *budget, USA gross income* y *worldwide gross income*.
  - En la base de datos de The Movies Database, tenemos 26 millones de entradas.
  - Lenguaje de las películas, moneda en la cual están expresados los *budjets* e *incomes*.
- Algunas variables han cambiado con el tiempo, por ejemplo hay más ratings que la base de datos del año pasado, pero no podemos compararlas.



Datos

- Contamos con dos bases de datos, The movies Dataset de Rounak Banik
- IMDb movies extensive dataset de Stefano Leone, ambas extraídas del portal Kaggle.
- The movies Dataset está diseado con la idea de hacer un sistema de recomendación a base de él, mientras que se ha usado el de IMDb para entender a la industria.
- Ambos datasets son de forma tabular.



The Movies Dataset

El Dataset está compuesto de varios archivos. Contiene metadata de 45,000 películas. Conciste de películas lanzadas antes o en julio de 2017. Algunas de las columnas de este data set son:

- Cast
- Crew
- Plot keywords,
- Budget
- Revenue
- Posters
- Release dates
- Languages
- Production companies
- Countries
- IMDb vote counts and vote averages

También contiene un archivo con 26 millones de ratings de 270,000 usuarios de más de 45,000 películas. Los raitings se encuentran en una escala de 1-5.

Archivos de The movies Dataset

- movies_metadata.csv
- keywords.csv: Palabras clave de la trama.
- credits.csv: Cast y crew de las películas.
- links.csv: TMDB, IMDB IDs de todas las películas.
- links_small.csv
- ratings.csv

IMDb

La base de datos de IMDb consiste en cuatro tablas: *movies*, *ratings*, *names* y *title principals*.

- *Movies*: incluye 85, 855 películas con su descripción, rating promedio, número de votantes, género, etc. (22 variables)
- *Ratings*: incluye 85, 855 ratings detallados desde una perspectiva demográfica. (49 variables)
- *Names*: incluye 297, 705 miembros de cast con sus atributos personales como fecha de nacimiento, peso, hijos, etc. (17 variables)
- *Title principals*: incluye 835, 513 papeles de miembros principales del cast en las películas. (6 variables)

Estos datos fueron obtenidos de https://www.imdb.com por Stefano Leone.



Referencias

- Banik, R. The Movies Dataset, 2017. Recuperado el 27 de agosto de 2021 en https://www.kaggle.com/rounakbanik/the-movies-dataset?select=ratings.csv

- Leone, S. IMDb movies extensive dataset, 2020. Recuperado el 27 de agosto de 2021 en https://www.kaggle.com/stefanoleone992/imdb-extensive-dataset

- MovieLens: https://grouplens.org/datasets/movielens/latest/

